### LAB5 Report

## Environment setup

GPU: GeForce Titan RTX

CUDA version: 10.1

TensorRT version: 7.0.0

## Baseline

### **Training setup:**

```
batch size:32
```

Transforms function:

transforms.Compose([

transforms. Random Resized Crop (224),

transforms.RandomHorizontalFlip(),

transforms.ToTensor(),

transforms.Normalize([0.485, 0.456, 0.406], [0.229, 0.224, 0.225])

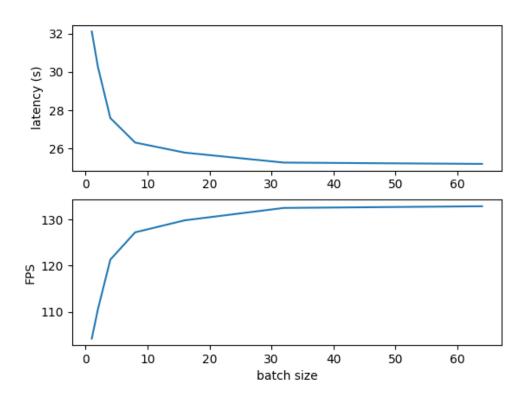
#### Result:

```
Test acc: 94.3830, time: 36.3968
```

### Onnx:

### TensorRT:

準確率並沒有太大的改變,FPS及latency的曲線如下:



可以發現隨著batch size增加,latency減少而FPS增加。

# Conclusion:

整體來說我覺得Inference time沒有減少想像中的多,如果是我會傾向在研究減少training的時間。另外tensorRT的相關資料較少,需要花比較多時間研究,